

Matemática Computacional
MEBiol, MEBiom e MEFT
Aula 12 - Resolução numérica de sistemas de
equações

Ana Leonor Silvestre

Instituto Superior Técnico, 1^o Semestre, 2020/2021

Sumário da Aula 12

Cap. 3 - Resolução numérica de sistemas de equações

Convergência dos métodos de Jacobi e Gauss-Seidel em sistemas com matriz de diagonal dominante.

Convergência do método de Gauss-Seidel em sistemas com matriz simétrica e definida positiva.

Raio espectral de uma matriz. Condição necessária e suficiente de convergência.

Método de Newton para a resolução numérica de sistemas não-lineares.

Sistemas de equações lineares

Condições de convergência dos métodos de Jacobi e Gauss-Seidel em termos da matriz A

- ▶ Os algoritmos dos métodos de Jacobi e Gauss-Seidel não requerem explicitamente as respectivas matrizes de iteração, uma vez que as entradas da matriz A e as componentes do vetor b são usados diretamente no algoritmo para obter as sucessivas iteradas dos métodos.
- ▶ Pretendemos deduzir condições que permitam assegurar a convergência dos métodos de Jacobi e Gauss-Seidel analisando diretamente a matriz A .

Sistemas com matriz de diagonal estritamente dominante

Começamos por tentar perceber o que significa a condição

$$\|C_J\|_\infty < 1$$

em termos de propriedades da matriz A .

É fácil ver que

$$(C_J)_{ij} = \begin{cases} -\frac{a_{ij}}{a_{ii}}, & i \neq j, \\ 0, & i = j \end{cases}$$

pelo que

$$\|C_J\|_\infty < 1 \iff \max_{1 \leq i \leq N} \sum_{j=1}^N |c_{ij}| < 1$$

$$\iff \max_{1 \leq i \leq N} \sum_{j=1, j \neq i}^N \frac{|a_{ij}|}{|a_{ii}|} < 1 \iff \sum_{j=1, j \neq i}^N \frac{|a_{ij}|}{|a_{ii}|} < 1, \forall i \in \{1, \dots, N\}$$

ou seja, se a matriz A satisfaz $|a_{ii}| > \sum_{j=1, j \neq i}^N |a_{ij}|, \forall i \in \{1, \dots, N\}$.

Sistemas com matriz de diagonal estritamente dominante

Definição

Diz-se que $A \in \mathbb{R}^{N \times N}$ tem diagonal estritamente dominante por linhas (resp. por colunas) se

$$|a_{ii}| > \sum_{j=1, j \neq i}^N |a_{ij}|, \forall i \in \{1, \dots, N\}$$

$$(\text{resp. } |a_{jj}| > \sum_{i=1, i \neq j}^N |a_{ij}|, \forall j \in \{1, \dots, N\}).$$

Teorema

Seja $A \in \mathbb{R}^{N \times N}$ com diagonal principal estritamente dominante por linhas ou por colunas. Então A é não singular e os métodos de Jacobi e Gauss-Seidel são convergentes para a solução do sistema $Ax = b$, qualquer que seja a iterada inicial $x^{(0)} \in \mathbb{R}^N$.

Sistemas com matriz de diagonal estritamente dominante

Exemplo

No sistema

$$4x_1 - 2x_2 + x_3 = 1$$

$$-2x_1 + 10x_2 - 0.5x_3 = 2$$

$$x_1 - 0.5x_2 + 2x_3 = 3$$

a matriz

$$\begin{bmatrix} 4 & -2 & 1 \\ -2 & 10 & -0.5 \\ 1 & -0.5 & 2 \end{bmatrix}$$

tem diagonal estritamente dominante por linhas e por colunas (é simétrica):

$$4 > |-2| + 1, 10 > |-2| + |-0.5|, 2 > 1 + |-0.5|.$$

Exemplo

Aplicando o método de Jacobi ao sistema linear equivalente

$$\begin{array}{lcl} x_1 - 0.5x_2 + 2x_3 = 3 & & 4x_1 - 2x_2 + x_3 = 1 \\ -2x_1 + 10x_2 - 0.5x_3 = 2 & \iff & -2x_1 + 10x_2 - 0.5x_3 = 2 \\ 4x_1 - 2x_2 + x_3 = 1 & & x_1 - 0.5x_2 + 2x_3 = 3 \end{array}$$

Fica

$$\begin{aligned} x_1^{(k+1)} &= 3 + 0.5x_2^{(k)} - 2x_3^{(k)} \\ x_2^{(k+1)} &= 0.2 + 0.2x_1^{(k)} + 0.05x_3^{(k)} \\ x_3^{(k+1)} &= 1 - 4x_1^{(k)} + 2x_3^{(k)}, \quad k = 0, 1, 2, \dots \end{aligned}$$

Iterando a partir de $x^{(0)} = [1 \ 0 \ 0]^T$, obtém-se

$$\begin{aligned} x^{(1)} &= [3, \ 0.4, \ -3]^T, \\ x^{(2)} &= [9.199999999999999, \ 0.65, \ -10.199999999999999]^T, \\ x^{(3)} &= [23.724999999999998, \ 1.53, \ -34.5]^T, \dots \end{aligned}$$

Parece que não há convergência... **Importante:** aplicar o método de Jacobi ao sistema em que a matriz tem diagonal dominante.

Sistemas com matriz simétrica e definida positiva

Definição

Uma matriz $A \in \mathbb{R}^{N \times N}$ diz-se definida positiva se

$$x^T A x > 0, \forall x \in \mathbb{R}^N \setminus \{0\}.$$

Algumas propriedades das matrizes definidas positivas:

- ▶ $A \in \mathbb{R}^{N \times N}$ é definida positiva $\Leftrightarrow A + A^T$ é definida positiva.
- ▶ $A \in \mathbb{R}^{N \times N}$ é definida positiva $\Leftrightarrow \det(A_k) > 0$, para todo $k \in \{1, \dots, N\}$, onde as submatrizes $A_k \in \mathbb{R}^{k \times k}$ consistem nos elementos das primeiras k linhas e k colunas da matriz A .

Para matrizes simétricas tem-se ainda:

- ▶ $A \in \mathbb{R}^{N \times N}$ é definida positiva \Leftrightarrow todos os valores próprios de A são positivos.
- ▶ $A \in \mathbb{R}^{N \times N}$ é definida positiva $\Rightarrow z^* A z > 0, \forall z \in \mathbb{C}^N \setminus \{0\}$.

Método de Gauss-Seidel para sistemas com matriz simétrica e definida positiva

Teorema

Seja $A \in \mathbb{R}^{N \times N}$ simétrica e definida positiva. Então o método de Gauss-Seidel é convergente para a solução dos sistema $Ax = b$, qualquer que seja a iterada inicial $x^{(0)} \in \mathbb{R}^N$.

Raio espectral e relação com normas matriciais

Definição

Se $C \in \mathbb{R}^{N \times N}$, $\sigma(C) \subset \mathbb{C}$ designa o *espectro* de C , ou seja, o conjunto de todos os valores próprios da matriz C . Ao número $\varrho(C) = \max_{\lambda \in \sigma(C)} |\lambda|$ chama-se **raio espectral** de C .

A primeira relação entre normas matriciais e raio espectral envolve a norma $\|\cdot\|_2$:

$$\|C\|_2 = (\varrho(C^*C))^{\frac{1}{2}}, \forall C \in \mathbb{R}^{N \times N}.$$

Relações entre normas matriciais e raio espectral

O raio espectral pode ser entendido como o *ínfimo de todas as normas matriciais induzidas*, de acordo com os seguintes resultados:

(i) Qualquer que seja a norma matricial induzida $\|\cdot\|$, tem-se

$$\varrho(C) \leq \|C\|, \forall C \in \mathbb{R}^{N \times N}.$$

(ii) Para cada $C \in \mathbb{R}^{N \times N}$ e cada $\varepsilon > 0$, existe uma norma matricial induzida $\|\cdot\|$ tal que

$$\|C\| \leq \varrho(C) + \varepsilon.$$

Fórmula de Gelfand: seja $C \in \mathbb{R}^{N \times N}$. Para qualquer norma matricial induzida $\|\cdot\|$, tem-se

$$\varrho(C) = \lim_{n \rightarrow \infty} \|C^n\|^{1/n}.$$

Condição necessária e suficiente de convergência para métodos iterativos para sistemas lineares

Teorema

Sejam $C \in \mathbb{R}^{N \times N}$, $d \in \mathbb{R}^N$ e suponhamos que $z = Cz + d$. O método do ponto fixo

$$x^{(n+1)} = Cx^{(n)} + d, \quad n \in \mathbb{N}_0,$$

converge para z , qualquer que seja $x^{(0)} \in \mathbb{R}^N$, se e só se

$$\rho(C) < 1.$$

Se $\rho(C) = 0$ então z é obtido ao fim de um número finito de iterações (no máximo n).

Demonstração

(i) Se $\varrho(C) < 1$ então existe $\varepsilon > 0$ tal que

$$\varrho(C) + \varepsilon < 1.$$

Neste caso, existe uma norma matricial induzida $\|\cdot\|$ tal que

$$\|C\| \leq \varrho(C) + \varepsilon < 1$$

e, por um teorema anterior, esta condição é suficiente para a existência e unicidade de z e para a convergência do método iterativo.

Demonstração

(ii) Se $\varrho(C) \geq 1$, sejam $\lambda \in \mathbb{C}$ com $|\lambda| \geq 1$ e $v \in \mathbb{C}^N \setminus \{0\}$ tais que

$$Cv = \lambda v.$$

Como $z - x^{(n)} = C(z - x^{(n-1)})$, os erros satisfazem

$$z - x^{(n)} = C^n(z - x^{(0)}) \quad (n \in \mathbb{N}_0).$$

Se $v \in \mathbb{R}^N$ e escolhermos $x^{(0)} = z - v$, de

$$z - x^{(n)} = C^n(z - x^{(0)}) = C^n v = \lambda^n v$$

resulta

$$\|z - x^{(n)}\| = |\lambda|^n \|v\| \geq \|v\|, \quad \forall n \in \mathbb{N}_0,$$

para qualquer norma em \mathbb{R}^N . Nesta situação, não há convergência.

Demonstração

(iii) Se $\varrho(C) = 0$ então $\lambda = 0$ é o único valor próprio de C e o polinómio característico de p é dado por

$$p(t) = t^N.$$

Pelo Teorema de Caley-Hamilton, tem-se

$$p(C) = C^N = 0$$

e portanto

$$z - x^{(N)} = C^N(z - x^{(0)}) = 0.$$

Rapidez de convergência dos métodos estudados

Seja

$$x^{(n+1)} = Cx^{(n)} + d, \quad n \in \mathbb{N}_0.$$

Como

$$z - x^{(n)} = C^n(z - x^{(0)})$$

e

$$\varrho(C) = \lim_{n \rightarrow \infty} \|C^n\|^{\frac{1}{n}},$$

tem-se

$$\|z - x^{(n)}\| \approx \varrho(C)^n \|z - x^{(0)}\|, \text{ para } n \text{ suficientemente grande,}$$

pelo que $\varrho(C)$ pode ser entendido como uma medida da rapidez de convergência dos métodos iterativos da forma $x^{(n+1)} = Cx^{(n)} + d$, $n \in \mathbb{N}_0$.

Quanto menor for $\varrho(C)$ mais rápida será a convergência.

Exercício

Considere o método iterativo

$$\begin{cases} x_1^{(k+1)} = -9x_1^{(k)} - 5x_2^{(k)} + 20 \\ x_2^{(k+1)} = -90x_1^{(k)} - 59x_2^{(k)} + 80, \quad k = 0, 1, 2, \dots \end{cases}$$

O que pode dizer sobre a convergência do método?

Exercício

A matriz de iteração é

$$C = - \begin{bmatrix} 9 & 5 \\ 90 & 59 \end{bmatrix}.$$

Vamos analisar o raio espectral de C :

$$\det(\lambda I - C) = 0 \iff (\lambda + 9)(\lambda + 59) - 450 = 0$$

$$\iff \lambda^2 + 68\lambda + 81 = 0 \iff \lambda = -34 - 5\sqrt{43}, \lambda = -34 + 5\sqrt{43}$$

pelo que

$$\varrho(C) > 1.$$

Assim, não está garantida a convergência para qualquer $x^{(0)} \in \mathbb{R}^2$.

Sistemas de equações não lineares

Exemplo - Sistema de equações não lineares

$$\begin{cases} x^2 + xy = 10 \\ y + 3xy^2 = 57 \end{cases}$$




Figura: Localização das raízes através de um gráfico

Exemplo

No **Mathematica** a função `FindRoot` permite resolver numericamente **equações não lineares**.

In : `FindRoot[{x^2+x*y == 10, y+3x*y^2 == 57}, {{x, 1.5}, {y, 3.5}}]`

Out : `{x-> 2., y-> 3.}`

`FindRoot[{x^2 + x * y == 10, y + 3x * y^2 == 57}, {{x, 5}, {y, -1}}]`

`{x-> 4.39374, y-> -2.11778}`

Método de Newton generalizado

$$\left\{ \begin{array}{l} x^{(0)} \text{ dado} \\ J_f(x^{(k)})\Delta x^{(k)} = -f(x^{(k)}) \\ x^{(k+1)} = x^{(k)} + \Delta x^{(k)}, \quad k = 0, 1, 2, \dots \end{array} \right.$$

Teorema (da convergência local). Seja $f \in C^2(V_z)$, onde V_z é uma vizinhança de z , zero de f , tal que $\det(J_f(z)) \neq 0$. Então o método de Newton converge para z desde que $x^{(0)}$ esteja suficientemente perto de z .

Exemplo

$$\begin{cases} x_1^2 + x_1x_2 = 10 \\ x_2 + 3x_1x_2^2 = 57 \end{cases} \Leftrightarrow f(x) = 0$$

com

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$$

$$f(x_1, x_2) = \begin{bmatrix} x_1^2 + x_1x_2 - 10 \\ x_2 + 3x_1x_2^2 - 57 \end{bmatrix}$$

e a matriz Jacobiana de f é dada por

$$J_f(x_1, x_2) = \begin{bmatrix} 2x_1 + x_2 & x_1 \\ 3x_2^2 & 1 + 6x_1x_2 \end{bmatrix}.$$

Exemplo

A primeira iterada do método de Newton $x^{(1)} = x^{(0)} + \Delta x^{(0)}$ obtém-se resolvendo o sistema linear

$$J_f(x^{(0)})\Delta x^{(0)} = -f(x^{(0)})$$

com $x^{(0)} = [1.5 \ 3.5]^T$. Tem-se

$$f(x^{(0)}) = \begin{bmatrix} -2.5 \\ 1.625 \end{bmatrix} \quad J_f(x^{(0)}) = \begin{bmatrix} 6.5 & 1.5 \\ 36.75 & 32.5 \end{bmatrix}$$

e

$$\Delta x^{(0)} = [0.536029 \ -0.656125]^T$$

pelo que $x^{(1)} = x^{(0)} + \Delta x^{(0)} = [2.03603 \ 2.84388]^T$.

Exemplo

Analogamente, $x^{(2)} = x^{(1)} + \Delta x^{(1)}$, onde $\Delta x^{(1)}$ é a solução do sistema linear

$$J_f(x^{(1)})\Delta x^{(1)} = -f(x^{(1)}).$$

Com $x^{(1)} = [2.03603 \ 2.84388]^T$, tem-se

$$f(x^{(1)}) = \begin{bmatrix} -0.0643568 \\ -4.756 \end{bmatrix} \quad J_f(x^{(1)}) = \begin{bmatrix} 6.91594 & 2.03603 \\ 24.263 & 35.7413 \end{bmatrix}$$

pelo que

$$\Delta x^{(1)} = [-0.0373293 \ 0.158408]^T$$

e

$$x^{(2)} = x^{(1)} + \Delta x^{(1)} = [1.9987 \ 3.00229]^T$$

$$x^{(3)} = [1.99999 \ 2.99999]^T$$