

Capítulo 3. Variáveis aleatórias e distribuições discretas

Conceição Amado, Ana Pires e M. Rosário Oliveira

3.1 - Variáveis aleatórias. Função de distribuição: tipos de variáveis aleatórias.

Ao descrever-se o espaço de resultados de uma experiência aleatória os acontecimentos elementares não têm que ser numéricos, o que dificulta a aplicação de procedimentos matemáticos.

Em muitas situações não interessam todos os aspectos resultantes de uma dada experiência aleatória mas apenas um valor numérico.

Surge assim a necessidade de definição de **funções reais**, associadas à experiência aleatória, que permitam:

- ▶ associar a um valor real cada acontecimento elementar;
- ▶ preservar a sua distribuição de probabilidades.

Informalmente pode-se dizer que variável aleatória é uma função que associa um número real a cada um dos elementos do espaço de resultados de uma experiência aleatória.

3.1 - Variáveis aleatórias

Definição: Considere uma experiência aleatória e Ω o seu espaço de resultados. À função $X(\omega)$ tal que $X : \Omega \longrightarrow \mathbb{R}$ diz-se uma **variável aleatória (v.a.)** se para qualquer $x \in \mathbb{R}$, o conjunto de Ω , $\{\omega \in \Omega : X(\omega) \leq x\}$ é um acontecimento.

$$\begin{array}{ccc} \Omega & \longrightarrow & \mathbb{R} \\ \omega & & X(\omega) \\ & X & \end{array}$$

Observações:

1. representam-se, geralmente, pelas últimas letras maiúsculas do alfabeto latino, $X, Y, Z, X_1, Y_1, Z_1, \dots$;
2. um valor particular representa-se por uma letra minúscula;
3. $P(X = x) = P(X(\omega) = x) = P\{\omega \in \Omega : X(\omega) = x\}$
4. num mesmo espaço de resultados podem definir-se diversas variáveis aleatórias.

3.1 - Função de distribuição

Definição: Define-se **função de distribuição (cumulativa)** de uma v.a. X à função real de valor real, $F_X : \mathbb{R} \rightarrow [0, 1]$, que a cada $x \in \mathbb{R}$ faz corresponder a probabilidade do acontecimento $\{\omega : X(\omega) \leq x\}$, representa-se

$$F_X(x) = P(X \leq x).$$

Algumas propriedades da função de distribuição:

1. $0 \leq F_X(x) \leq 1, \forall x \in \mathbb{R}$;
2. $F_X(x)$ é não decrescente;
3. $\lim_{x \rightarrow -\infty} F_X(x) = 0$ e $\lim_{x \rightarrow +\infty} F_X(x) = 1$;
4. $F_X(x)$ é contínua à direita;
5. $P(X = x_0) = F_X(x_0) - F_X(x_0^-) = F_X(x_0) - \lim_{x \rightarrow x_0} F_X(x)$;
6. $P(x_0 < X \leq x_1) = F_X(x_1) - F_X(x_0)$, com $x_0 < x_1$.

3.1 - Tipos de variáveis aleatórias.

D_X o conjunto (numerável) de pontos de descontinuidade de $F_X(x)$:

- ▶ A v.a. X diz-se **discreta** quando $P(X \in D_X) = 1 \rightarrow \text{CAP. 3}$
- ▶ A v.a. X diz-se **contínua** quando $D_X = \emptyset$. $\rightarrow \text{CAP. 4}$
- ▶ A v.a. X diz-se **mista** quando $D_X \neq \emptyset$ e $P(X \in D_X) < 1$.

Observação:

- ▶ Em alternativa também se pode definir v.a. discreta se o conjunto dos seus possíveis valores for um conjunto finito ou infinito numerável.

3.1 - Tipos de variáveis aleatórias

Exemplo 3.1: Considere a experiência aleatória (E.A.):

$E.A.$ = “Medição do tempo de funcionamento (tempo de vida), em horas, de uma componente”, com $\Omega = [0, +\infty[$.

Definam-se as seguintes variáveis aleatórias:

- T - “v.a. que indica o tempo de vida (duração) da componente”
Valores possíveis desta v.a. $(R_T) \longrightarrow$ coincidem com o espaço de resultados; $R_T = \mathbb{R}_0^+ \implies T$ **não é discreta**
- Z - “v.a. que indica se a duração é maior ou não que 100 horas.”

$$Z = \begin{cases} 0, & T \leq 100 \\ 1, & T > 100 \end{cases}$$

$$R_Z = \{0, 1\} \implies Z \text{ é discreta}$$


- W - v.a. definida como:

$$W = \begin{cases} 0, & T \leq 100 \\ T - 100, & T > 100 \end{cases}$$


$$R_W = \{0\} \cup \mathbb{R}^+ \implies W \text{ é mista}$$

3.1 - Tipos de variáveis aleatórias


Esboço dos gráficos das funções de distribuição, F_T , F_Z e F_W :



T v.a. contínua



Z v.a. discreta



W v.a. mista

3.2 - Variáveis aleatórias discretas. Função (massa) de probabilidade

Exemplo 3.2: Lançamento de duas moedas equilibradas e observar o número de coroas.

$\Omega = \{(F, F), (C, F), (F, C), (C, C)\}$, onde F = "saída de Face" e C = "saída de Coroa";

Seja

Y - "v.a. número de coroas obtidas no lançamento."

Y é discreta e pode tomar os valores $y = 0, 1, 2$: $R_Y = \{0, 1, 2\}$

$$P(Y = 0) = P(\{(F, F)\}) = \frac{1}{4}$$

$$P(Y = 1) = P(\{(F, C), (C, F)\}) = \frac{1}{2}$$

$$P(Y = 2) = P(\{(C, C)\}) = \frac{1}{4}$$

3.2 - Variáveis aleatórias discretas.

Exemplo 3.3: E.A. “Lançamentos sucessivos de um dado equilibrado até sair face 6.”

$$\Omega = \{(6), (1, 6), (2, 6), \dots, (5, 6), (1, 1, 6), \dots, (5, 5, 6), \dots\}$$

X - “v.a. que indica o número de lançamentos até sair a face 6”

X é discreta, os valores possíveis são $y = 1, 2, 3, \dots$, $R_X = \mathbb{N}$

$$P(X = 1) = \frac{1}{6}$$

$$P(X = 2) = \frac{5}{6} \times \frac{1}{6}$$

$$P(X = 3) = \left(\frac{5}{6}\right)^2 \times \frac{1}{6}, \dots$$

$$P(X = x) = \left(\frac{5}{6}\right)^{x-1} \times \frac{1}{6}, \quad x \in \mathbb{N}$$

3.2 - Função de probabilidade

Definição: Seja X v.a. discreta assumindo valores em $R_X = \{x_1, x_2, \dots\}$. A **função (massa) de probabilidade** de X é dada por:

$$P(X = x) = \begin{cases} P(X = x_i), & x = x_i \in R_X \\ 0, & \text{c.c.} \end{cases}$$

e satisfaz:

- ▶ $P(X = x) \geq 0, \forall x \in \mathbb{R};$
- ▶ $\sum_{x \in \mathbb{R}} P(X = x) = \sum_{x \in R_X} P(X = x) = 1.$


Nota:

Esta função pode ser denotada por: $P(X = x)$, $P_X(x)$, $f_X(x)$ ou $f(x)$.

3.2 - Função de probabilidade

Exemplo 3.2 (cont.): A função de probabilidade de Y - v.a. “número de coroas obtidas no lançamento”, é:

$$P(Y = y) = \begin{cases} 1/4, & y = 0, 2 \\ 1/2, & y = 1 \\ 0, & y \notin \{0, 1, 2\} \end{cases}$$



3.2 - Função de probabilidade

Exemplo 3.3 (cont.): A função de probabilidade de X - “v.a. número de lançamentos até sair a face 6”, é

$$f(x) = P(X = x) = \begin{cases} \left(\frac{5}{6}\right)^{x-1} \times \frac{1}{6}, & x \in \mathbb{N} \\ 0, & \text{c.c.} \end{cases}$$

É fácil verificar que

$$\sum_{x=1}^{\infty} \left(\frac{5}{6}\right)^{x-1} \times \frac{1}{6} = \frac{1/6}{1 - 5/6} = 1$$

(soma da série geométrica de razão 5/6 e 1.º termo 1/6)

3.2 - Variáveis aleatórias discretas.

Observações:

Quando X é v.a. discreta:

1. $P(X \in A) = \sum_{x_i \in A} P(X = x_i), \forall A \subset \mathbb{R};$
2. A **função de distribuição** (ou função de distribuição acumulada) de uma v.a. discreta, X , é

$$F_X(x) = P(X \leq x) = \sum_{x_i \leq x} P(X = x_i), x \in \mathbb{R}$$

é então uma função “em escada”. Os “saltos” são o valor da função de probabilidade no ponto correspondente;

3. A função de distribuição é contínua à direita.

3.2 - Variáveis aleatórias discretas.

4. O cálculo de probabilidades à custa de $F_X(x)$ é simples:

$$P(X = x) = F_X(x) - F_X(x^-);$$


$$P(X > x) = 1 - F_X(x);$$

$$P(x_0 < X \leq x_1) = F_X(x_1) - F_X(x_0), x_0 < x_1.$$

$$P(x_0 \leq X < x_1) = F_X(x_1^-) - F_X(x_0^-), x_0 < x_1.$$

Exemplo 3.2 (cont.):

$$F_Y(y) = \begin{cases} 0 & y < 0 \\ 1/4 & 0 \leq y < 1 \\ 3/4 & 1 \leq y < 2 \\ 1 & y \geq 2 \end{cases}$$



3.3 Valor esperado, variância e algumas das suas propriedades. Moda e quantis.

Quer a função de distribuição quer a função de probabilidade caracterizam completamente uma v.a. discreta. No entanto, podemos estar interessados em outras medidas que caracterizem de forma parcial a v.a.. Entre essas medidas podem destacar-se:

- ▶ **Medidas (parâmetros) de localização:**

- ▶ Valor esperado;
- ▶ Moda;
- ▶ Mediana;
- ▶ Quantis.

- ▶ **Medidas (parâmetros) de dispersão:**

- ▶ Variância;
- ▶ Desvio padrão.

3.3 Valor esperado

Definição: O **valor esperado, valor médio, ou média** de uma v.a. discreta, X , com função de probabilidade $f_X(x) = P(X = x)$, representa-se por $E(X)$, μ_X ou μ e é dado por

$$E(X) = \sum_x x P(X = x).$$

Observações:

1. $E(X)$ é um valor numérico nas mesmas unidades que a variável X , mas não é necessariamente um dos valores que a variável pode tomar.
2. Quando X pode tomar um n.º infinito de valores (Exemplo 3.3 da secção anterior), $E(X)$ é dado pela soma de uma série, que pode não ser convergente, nesse caso diz-se que não existe valor esperado.
3. O valor esperado corresponde ao conceito físico de centro de gravidade (de um sistema unidimensional discreto em que os pontos têm coordenadas x_i e massas $P(X = x_i)$).

3.3 Valor esperado: propriedades

1) Valor esperado de uma função de X

$$E[h(X)] = \sum_x h(x) P(X = x)$$

Em geral tem-se $E[h(X)] \neq h[E(X)]$, excepto no casos em que h é uma função linear ou a v.a. é degenerada (ou seja, é uma constante).

2) Se X é v.a. inteira não negativa, então:

$$E(X) = \sum_{x=0}^{+\infty} P(X > x) = \sum_{x=0}^{+\infty} [1 - F_X(x)]$$

3.3 Valor esperado: propriedades

3) O operador **valor esperado é linear**

$$E(aX + b) = aE(X) + b, \quad \forall a, b \in \mathbb{R}$$

Demonstração:

$$\begin{aligned} E(aX + b) &= \sum_x (ax + b) P(X = x) = \\ &= \left(\sum_x ax P(X = x) \right) + \left(\sum_x b P(X = x) \right) = \\ &= a \underbrace{\sum_x x P(X = x)}_{E(X)} + b \underbrace{\sum_x P(X = x)}_1 = aE(X) + b \end{aligned}$$

Caso particular: $E(b) = b, \quad \forall b \in \mathbb{R}$

3.3 Valor esperado: propriedades

Exemplo: Considere-se novamente a v.a. Y com $P(Y = 0) = \frac{1}{4}$, $P(Y = 1) = \frac{1}{2}$, $P(Y = 2) = \frac{1}{4}$ que representa o número de coroas no lançamento de duas moedas equilibradas.

Imagine o seguinte jogo: paga-se um preço para lançar as duas moedas e recebe-se um prémio de Y^2 Euros. Qual o preço justo a pagar?

Como o valor equilibrado a longo prazo é $E(Y^2)$ e a função de probabilidade de Y^2 é dada por:

| i | 0 | 1 | 4 |
|--------------|---------------|---------------|---------------|
| $P(Y^2 = i)$ | $\frac{1}{4}$ | $\frac{1}{2}$ | $\frac{1}{4}$ |

$$\text{logo } E(Y^2) = 0 \times \frac{1}{4} + 1 \times \frac{1}{2} + 4 \times \frac{1}{4} = 1.5 \text{ (Euros).}$$

Notar que $E(Y^2) \neq [E(Y)]^2 = \left(0 \times \frac{1}{4} + 1 \times \frac{1}{2} + 2 \times \frac{1}{4}\right)^2 = 1$.

3.3 Moda



Definição: **Moda** de uma v.a. discreta, X com função de probabilidade $f_X(x)$ representa-se por μ_o ou $Mo(X)$ e é o valor, ou valores, com máxima probabilidade de ocorrência

$$\mu_o = \text{moda de } X : f_X(\mu_o) = \max_x f_X(x)$$

ou equivalente:

$$\mu_o = \arg \max_x f_X(x)$$

Observação: A moda pode não ser única. Podem definir-se modas relativas (correspondentes a máximos relativos).



3.3 Quantis

Definição: **Mediana** de uma v.a. **discreta** X com função de distribuição $F_X(x)$, representa-se por μ_e ou me_X e é um ponto central em termos de probabilidade, ou seja, tal que, se possível, $P(X \leq \mu_e) = P(X \geq \mu_e)$


$$\mu_e : \quad P(X \leq \mu_e) \geq \frac{1}{2} \quad \text{e} \quad P(X \geq \mu_e) \geq \frac{1}{2}$$

que é equivalente:

$$\mu_e : \quad \frac{1}{2} \leq F_X(\mu_e) \leq \frac{1}{2} + P(X = \mu_e)$$

3.3 Quantis

Graficamente:



3.3 Quantis

Generalização da ideia de mediana:

Definição: **Quantil de ordem p** ($0 < p < 1$) de uma v.a. discreta, X com função de distribuição $F_X(x)$, denota-se por $\chi_p = F_X^{-1}(p)$ e é dado por

$$\chi_p : \quad P(X \leq \chi_p) \geq p \quad \text{e} \quad P(X \geq \chi_p) \geq 1 - p$$

que é equivalente:

$$\chi_p : \quad p \leq F_X(\chi_p) \leq p + P(X = \chi_p)$$

Observações:

- ▶ A mediana da v.a. X corresponde ao quantil de ordem $p = \frac{1}{2}$
- ▶ Aos quantis cujo p é múltiplo de $\frac{1}{4}$ chamam-se quartis.

3.3 Variância

Definição: A **variância**, de uma v.a. discreta, X com função de probabilidade $f_X(x)$ e valor esperado $\mu_X \equiv E(X)$, representa-se por $V(X)$, $\text{VAR}(X)$, σ_X^2 ou σ^2 e é dada por

$$V(X) = E \left[(X - \mu_X)^2 \right] = \sum_x (x - \mu_X)^2 f_X(x)$$

Observações:

1. A variância é um valor numérico expresso no quadrado das unidades da v.a. X .
2. Assim como pode não existir valor esperado, também pode não existir variância.
3. Do mesmo modo que o valor esperado é análogo do conceito físico de centro de gravidade, $V(X)$ é análoga do momento de inércia em relação a um eixo que passa pelo centro de gravidade.

3.3 Variância: Propriedades

Definição: O **desvio padrão**, de uma v.a. X , σ_X , é a raiz quadrada positiva de $V(X)$.

Observação: O desvio padrão é expresso nas unidades da variável.

Propriedades da variância

1) $V(X) \geq 0, \forall_X$ óbvio: $V(X) = \sum_x \underbrace{(x - \mu_X)^2}_{\geq 0} \underbrace{f_X(x)}_{\geq 0}$

2) $V(X) = E(X^2) - [E(X)]^2 = E(X^2) - E^2(X) = E(X^2) - \mu^2$

Dem.:

$$\begin{aligned} V(X) &= E[(X - \mu)^2] = E(X^2 - 2\mu X + \mu^2) = \\ &= E(X^2) - 2\mu \underbrace{E(X)}_{\mu} + \mu^2 = E(X^2) - 2\mu^2 + \mu^2 \end{aligned}$$

Nota: 1) e 2) $\Rightarrow E(X^2) \geq \mu^2$

3.3 Variância: Propriedades

Propriedades da variância (cont.)

3) $V(aX + b) = a^2 V(X)$, $\forall a, b \in \mathbb{R}$ (a variância não é um operador linear!)

Demonstração:

$$\begin{aligned} V(aX + b) &= E \left[(aX + b - E(aX + b))^2 \right] = \\ &= E \left[(aX + b - aE(X) - b)^2 \right] = \\ &= E \left[(aX - aE(X))^2 \right] = E \left[a^2 (X - E(X))^2 \right] = \\ &= a^2 E \left[(X - E(X))^2 \right] = a^2 V(X) \end{aligned}$$

3.3 Variância: Propriedades

Casos particulares:

- ▶ $V(b) = 0 \quad (a = 0)$
- ▶ $V(X + b) = V(X) \quad (a = 1)$
- ▶ $V(aX) = a^2 V(X) \quad (b = 0)$

$$4) V(X) = 0 \quad \Leftrightarrow \quad \exists_c : P(X = c) = 1$$

(ou seja, X é constante — também se diz “v.a. degenerada”)

3.3 Variância: Propriedades

Exemplo Considerem-se duas v.a. X e Y cujas funções de probabilidade são, respectivamente:

$$X: \begin{array}{c|ccc} x & -1 & 1 & c.c. \\ \hline f_X(x) & 1/2 & 1/2 & 0 \end{array} \quad Y: \begin{array}{c|ccc} y & -1000 & 1000 & c.c. \\ \hline f_Y(y) & 1/2 & 1/2 & 0 \end{array}$$

onde $E(X) = E(Y) = 0$. No entanto:

$$E(X^2) = (-1)^2 \times \frac{1}{2} + 1^2 \times \frac{1}{2} = 1 \text{ e}$$

$$E(Y^2) = (-1000)^2 \times \frac{1}{2} + 1000^2 \times \frac{1}{2} = 1000^2$$

$$V(X) = 1 \text{ e } V(Y) = 1000^2$$

$$\sigma_X = 1 \text{ e } \sigma_Y = 1000$$

3.4 Distribuição uniforme discreta

Definição: A v.a. X discreta diz-se ter **distribuição uniforme discreta no conjunto** $\{x_1, x_2, \dots, x_N\}$, de cardinal N , se tiver probabilidade $f_X(x; N) = P(X = x) = \frac{1}{N}$, para $x = x_1, x_2, \dots, x_N$ e $f_X(x) = 0$ nos restantes valores.

Notação: $X \sim Unif\{x_1, \dots, x_N\}$

Para esta distribuição tem-se:

$$E(X) = \frac{1}{N} \sum_{i=1}^N x_i$$

e

$$V(X) = E(X^2) - (E(X))^2 = \frac{1}{N} \sum_{i=1}^N x_i^2 - \left(\frac{1}{N} \sum_{i=1}^N x_i \right)^2$$

3.4 Distribuição uniforme discreta

Caso Particular:

Se $X \sim \{1, 2, \dots, N\}$,

tem-se:

$$\begin{aligned} \mu_X = E(X) &= \frac{N+1}{2} = \\ &= \sum_{i=1}^N i \frac{1}{N} = \frac{1}{N} \sum_{i=1}^N i = \frac{1}{N} \frac{N(N+1)}{2} \end{aligned}$$

$$\sigma_X^2 = V(X) = \frac{N^2 - 1}{12}$$

$$\text{Nota: } \sum_{i=1}^N i^2 = \frac{N(N+1)(2N+1)}{6}$$

✓ **Exemplo:** X - “v.a. que indica a face do dado (equilibrado) que ocorre em um lançamento”

$$X \sim \text{Unif}\{1, \dots, 6\}, E(X) = 3.5, V(X) = 35/12$$

Distribuição Bernoulli

Definição: Uma experiência aleatória chama-se **prova ou experiência de Bernoulli** quando só tem dois resultados possíveis: A ou \bar{A} .

- ▶ a ocorrência do acontecimento A tem probabilidade p :
 $P(A) = p$ ($0 < p < 1$);
- ▶ a ocorrência do acontecimento \bar{A} tem probabilidade $1 - p$:
 $P(\bar{A}) = 1 - p$ ($0 < p < 1$).

Nesta experiência designa-se por:

- ▶ **sucesso** à ocorrência do acontecimento A .
- ▶ **insucesso** à ocorrência do acontecimento \bar{A} .

Distribuição de Bernoulli

A partir de experiências de Bernoulli define-se uma variável aleatória X , com distribuição de Bernoulli, do seguinte modo: $X = 1$ se ocorre A e $X = 0$ se ocorre \bar{A} , com $R_X = \{0, 1\}$

Definição: A v.a. X discreta tem **distribuição de Bernoulli de parâmetro p , $0 < p < 1$** (escreve-se, $X \sim \text{Ber}(p)$) quando

$$P(X = x) = \begin{cases} p, & x = 1 \\ 1 - p, & x = 0 \\ 0, & \text{c.c.} \end{cases} \equiv \begin{cases} p^x(1 - p)^{1-x}, & x = 0, 1 \\ 0, & \text{c.c.} \end{cases},$$

Para esta distribuição tem-se:

- ▶ $E(X) = E(X^2) = p$;
- ▶ $V(X) = E(X^2) - E^2(X) = p - p^2 = p(1 - p)$;
- ▶ $F_X(x)$ tabelado para alguns valores de p .

Distribuição de Bernoulli

Exemplo da Urna: Considere-se uma urna com N bolas, das quais:

M são Brancas - característica associada ao “sucesso” (A)

$(N - M)$ são Pretas - característica associada ao “insucesso” (\bar{A})

E.A.- “Extrair 1 bola ao acaso”

X - “v.a.que indica a ocorrência do sucesso (bola Branca)”,

$$X \sim Ber(p = \frac{M}{N})$$

Admitindo que $N = 100$, $M = 20$, $(N - M) = 80$ tem-se $X \sim Ber(0.2)$.

- A distribuição de Bernoulli é muito importante para a definição das distribuições Binomial, Geométrica e Hipergeométrica.

3.6 Distribuição Binomial

O modelo probabilístico adequado para descrever uma experiência aleatória que consiste na repetição de n provas de Bernoulli independentes é a distribuição Binomial.

Definição: A v.a. X discreta que indica o n° de sucessos observados em n realizações independentes de provas de Bernoulli e com probabilidade de sucesso p em cada prova, diz-se ter **distribuição de Binomial de parâmetros, $n \in \mathbb{N}_0$ e $p \in]0, 1[$** (escreve-se, $X \sim \text{Bin}(n, p)$) e tem função de probabilidade igual a:

$$P(X = x) = \begin{cases} \binom{n}{x} p^x (1 - p)^{n-x}, & x = 0, 1, 2, \dots, n \\ 0, & \text{c.c.} \end{cases}$$

Para esta distribuição tem-se:

- ▶ $E(X) = np$
- ▶ $V(X) = np(1 - p)$
- ▶ $F_X(x)$ tabelado para alguns valores de n e p .

3.6 Distribuição Binomial

Observações:

- Recorrendo ao binómio de Newton:

$$(a + b)^n = \sum_{x=0}^n \binom{n}{x} a^x b^{n-x}$$

com $a = p$ e $b = 1 - p$ é imediato mostrar que $\sum_{x=0}^n P(X = x) = 1$,
pois

$$\sum_{x=0}^n P(X = x) = \sum_{x=0}^n \binom{n}{x} p^x (1 - p)^{n-x} = 1 \quad (\forall_{0 < p < 1}) \quad (1)$$

- Se $X \sim \text{Bin}(n, p) \Rightarrow Y = n - X \sim \text{Bin}(n, 1 - p)$
- Se $X \sim \text{Bin}(1, p) \Leftrightarrow X \sim \text{Ber}(p)$

3.6 Distribuição Binomial

Observações(cont.)– Cálculo de probabilidades para v.a. com distribuição binomial

- ▶ Se n pequeno: usar a fórmula de $P(X = k)$
- ▶ Se n grande:
 - ▶ Programas em computador ou calculadora
 - ▶ Tabelas, mas notar que:
 - ▶ Número limitado de situações cobertas: $n = 1, \dots, 20$ e $p = 0.01, 0.02, \dots, 0.09, 0.10, 0.15, 0.20, \dots, 0.50$
 - ▶ O que está tabelado é a função de distribuição. Recordar que a função de probabilidade se pode obter neste caso fazendo
$$P(X = k) = P(X \leq k) - P(X \leq k - 1) = F_X(k) - F_X(k - 1)$$
 - ▶ Aproximações (a ver posteriormente).

3.6 Distribuição Binomial: Exemplo 1

Exemplo da Urna: N bolas das quais M são Brancas e $(N - M)$ são Pretas

E.A.- “Extrair n bolas ao acaso e **com reposição**”

\Rightarrow n provas de Bernoulli independentes

X - “v.a. que indica o n° de sucessos (n° de bolas Brancas) nas n bolas”

Como $P(A_i) = \frac{M}{N} = p, i = 1, \dots, n$, e $P(A_i|A_{i-1}) = \frac{M}{N} = p$ tem-se que:

$$X \sim \text{Bin}(n, p = \frac{M}{N})$$

Para $N = 100$, $M = 20$, $(N - M) = 80$ e $n = 3$ temos que $X \sim \text{Bin}(3, 0.2)$.

Qual é a probabilidade de o n° de bolas brancas ser no máximo 1?

$$P(X \leq 1) = F_X(1) = 0.896 \text{ (consultando a tabela)}$$

3.6 Distribuição Binomial: Exemplo 2

Exemplo 2: Numa população muito grande, sabe-se que 50% das pessoas são a favor de jogos electrónicos infantis.

Se forem escolhidas 10 pessoas, ao acaso, qual é a probabilidade de encontrar 6 que são a favor de jogos electrónicos infantis?

E qual é a probabilidade de encontrar pelo menos 6 nas mesmas condições?

Resolução: Seja X - v.a. que indica o n.º de pessoas a favor de jogos electrónicos infantis nas 10 escolhidas

X representa o n.º de sucessos em 10 provas de Bernoulli que se podem considerar independentes (dado que a população é muito grande) com $p = 0.5$, logo $X \sim \text{Bin}(10, 0.5)$.

$$P(X = 6) = ?$$

$$P(X \geq 6) = ?$$

3.6 Distribuição Binomial: Exemplo 2

$$P(X = 6) = \binom{10}{6} \times \left(\frac{1}{2}\right)^{10} = \frac{210}{1024} = \frac{105}{512}$$

Em R: `> dbinom(6,10,0.5)` \longrightarrow `[1] 0.2050781`

Em Excel: `=BINOMDIST(6,10,0.5,FALSE)` \longrightarrow 0.205078125

Tabela (p. 1, canto inferior direito):

$$F_X(6) - F_X(5) = 0.8281 - 0.6230 = 0.2051$$

$$P(X \geq 6) = \sum_{x=6}^{10} \binom{10}{x} \left(\frac{1}{2}\right)^{10} = \dots = 1 - P(X < 6) = 1 - P(X \leq 5) = 1 - F_X(5)$$

Em R: `> 1-pbinom(5,10,0.5)` \longrightarrow `[1] 0.3769531`

Em Excel: `=1 - BINOMDIST(5,10,0.5,TRUE)` \longrightarrow 0.376953125

Tabela (p. 1, canto inferior direito): $1 - 0.6230 = 0.3770$

23 Mar 2020

3.7 Distribuição geométrica

Nas distribuições Binomial e Hipergeométrica o número de provas de Bernoulli (n) é fixo. Considere-se agora que temos uma sucessão infinita de provas de Bernoulli independentes até à realização do 1º sucesso.

Definição: Seja X a v.a. que indica o **nº de provas** de Bernoulli independentes e com probabilidade de sucesso constante (p), realizadas até à obtenção do **primeiro sucesso** (inclusive). Diz-se que X tem **distribuição geométrica** de parâmetro p , $X \sim \text{Geo}(p)$ e a sua função de probabilidade é:

$$P(X = x) = \begin{cases} (1 - p)^{x-1}p, & x = 1, 2, 3, \dots \\ 0, & \text{c.c.} \end{cases}$$

Valor esperado e variância:

$$E(X) = 1/p; V(X) = (1 - p)/p^2, \quad F_X(x) = \begin{cases} 1 - (1-p)^x, & x \geq 1 \\ 0, & \text{c.c.} \end{cases}$$

Exemplo da Urna: Qual é a probabilidade de ser necessário extraír (com reposição) no mínimo 3 bolas até encontrar a 1ª branca?

Dem Função distribuída:

$$x \geq 1, F_X(x) = P(X \leq x) = \sum_{k=1}^{\lfloor x \rfloor} (1-p)^{k-1} p = p \sum_{n=0}^{\lfloor x \rfloor - 1} (1-p)^n$$

$n = k-1$
 $1 \leq k \leq +\infty$
então $0 \leq n-1 \leq +\infty$

$$F_X(x) = p \frac{1 - (1-p)^{\lfloor x \rfloor}}{1 - (1-p)} = 1 - (1-p)^{\lfloor x \rfloor} \quad \text{QED}$$

Propriedade falta de memória da Geom(p):

Teo: Se $X \sim \text{Geom}(p)$ então $P(X > k+x | X > k) = P(X > x)$,
 $\forall x, k \in \mathbb{N}$

Dem:

$$P(X > k+x | X > k) = \frac{P(X > k+x, X > k)}{P(X > k)} = \frac{P(X > k+x)}{P(X > k)}$$

$$= \frac{(1-p)^{k+x}}{(1-p)^k} = (1-p)^x = 1 - [1 - (1-p)^x] = 1 - F_{\text{Geom}(p)}(x)$$

$$= P(X > x) \quad \text{QED}$$

Observação: • se X é va discreta e verifica a prop. falta de memória então $X \sim \text{Geom}(p)$
• a prop. de falta de memória da geométrica implica que:

$$X \sim \text{Geom}(p) \Rightarrow X - k | X > k \sim \text{Geom}(p), \forall k \in \mathbb{N}$$

3.5 Distribuição Hipergeométrica

O modelo probabilístico adequado para descrever uma experiência aleatória que consiste na repetição de n provas de Bernoulli dependentes (extrações sem reposição) é a distribuição Hipergeométrica.

Definição: (Exemplo da Urna) N bolas das quais M são Brancas e $(N - M)$ são Pretas ($M \leq N$)

E.A.- “Extraír n bolas (com $n \leq N$) ao acaso e sem reposição” \implies n provas de Bernoulli dependentes

X - “v.a. que indica o nº de sucessos (nº de bolas Brancas) nas n bolas”

Como $P(A_i) = \frac{M}{N} = p, i = 1, \dots, n$, (probabilidade do sucesso constante) mas $P(A_i|A_{i-1}) \neq \frac{M}{N} = p$ (provas de Bernoulli dependentes) X tem **distribuição hipergeométrica com parâmetros N, M e n** , $X \sim \text{Hip}(N, M, n)$, com função de probabilidade:

$$P(X = x) = \begin{cases} \frac{\binom{M}{x} \binom{N-M}{n-x}}{\binom{N}{n}}, & x = \max\{0, n - (N - M)\}, \dots, \min\{M, n\} \\ 0, & \text{c.c.} \end{cases}$$

3.5 Distribuição Hipergeométrica

Valores possíveis:

$$\text{Se } n \leq M \text{ e } n \leq N - M \quad x = 0, 1, 2, \dots, n$$

$$\text{Se } n > M \text{ e } n \leq N - M \quad x = 0, 1, 2, \dots, M$$

$$\text{Se } n \leq M \text{ e } n > N - M \quad x = n - (N - M), \dots, n$$

$$\text{Se } n > M \text{ e } n > N - M \quad x = n - (N - M), \dots, M$$

ou, englobando todos os casos,

$$x = \max\{0, n - (N - M)\}, \dots, \min\{M, n\}$$

3.5 Distribuição Hipergeométrica

Valor esperado e variância:

$$E(X) = n \frac{M}{N}$$

$$V(X) = n \frac{M}{N} \left(1 - \frac{M}{N}\right) \frac{N-n}{N-1}$$

Observações:

- ▶ Como $p = \frac{M}{N}$ tem-se $E(X) = np$ e $V(X) = np(1-p) \frac{N-n}{N-1}$ assim, $Bin(n, p)$ e $Hip(M, N, n)$ têm o mesmo valor médio e as variâncias apenas se distinguem pelo factor $\frac{N-n}{N-1}$.
- ▶ Quando N é grande e n pequeno comparado com N , esbate-se a diferença entre extracções com e sem reposição, i.e. $\frac{N-n}{N-1} \approx 1$.
- ▶ Se N grande e n pequeno em relação a N (regra prática: $n < 0.1N$), pode usar-se a distribuição binomial para calcular valores aproximados das probabilidades, i.e.

$$X \sim Hip(N, M, n) \approx \tilde{X} \sim Bin\left(n, p = \frac{M}{N}\right)$$

3.5 Distribuição Hipergeométrica: Exemplo 1

Exemplo da Urna: $N = 100$ bolas das quais $M = 20$ são Brancas e $(N - M) = 80$ são Pretas

E.A.- “Extrair 3 bolas ao acaso e **sem reposição**”

\Rightarrow 3 provas de Bernoulli dependentes

Y - “v.a. que indica o n° de sucessos (n° de bolas Brancas) nas 3 bolas”

$Y \sim \text{Hip}(N = 100, M = 20, n = 3)$ e a sua função de probabilidade é:

$$P(Y = y) = \begin{cases} \frac{\binom{20}{y} \binom{80}{3-y}}{\binom{100}{3}}, & y = 0, 1, 2, 3 \\ 0 & \text{c.c.} \end{cases}$$

Qual é a probabilidade de o n° de bolas brancas ser no máximo 1?

$$P(Y \leq 1) = F_Y(1) = \frac{\binom{20}{0} \binom{80}{3}}{\binom{100}{3}} + \frac{\binom{20}{1} \binom{80}{2}}{\binom{100}{3}} \quad (\text{não temos tabela da função de distribuição})$$

3.5 Distribuição Hipergeométrica: Exemplo 2

Exemplo:

Caixa com 100 peças das quais 10 são defeituosas. São efectuadas 5 extracções ao acaso, **sem reposição**.

Seja X - número de peças defeituosas encontradas nas 5 extracções;

Valores possíveis: $x = 0, 1, 2, 3, 4, 5$

$X \sim \text{Hip}(N = 100, M = 10, n = 5)$ e a sua função de probabilidade é:

$$P(X = x) = \frac{\binom{10}{x} \binom{90}{5-x}}{\binom{100}{5}}, \quad x = 0, 1, 2, 3, 4, 5$$

3.5 Distribuição Hipergeométrica: Exemplo 2

Nota:


Se as extracções forem efectuadas **com reposição** (o que em termos práticos é estranho!...) têm-se 5 provas de Bernoulli independentes com $P(\text{sucesso}) = 0.1$, ou seja $X \sim \text{Bin}(5, 0.1)$.

Comparação das probabilidades:

| | Sem reposição | Com reposição |
|-------------------|----------------------|----------------------|
| $P(X = 0) \simeq$ | 0.584 | 0.590 |
| $P(X = 1) \simeq$ | 0.339 | 0.328 |
| $P(X = 2) \simeq$ | 0.070 | 0.073 |
| $P(X = 3) \simeq$ | 0.006 | 0.008 |
| $P(X = 4) \simeq$ | 2.5×10^{-4} | 4.5×10^{-4} |
| $P(X = 5) \simeq$ | 3.3×10^{-6} | 1.0×10^{-5} |

A situação **com reposição**, embora irrealista, dá probabilidades próximas das calculadas para o caso **sem reposição**, esta aproximação é razoável já que $n < 0.1N$. *ie. $n = 5$, $0.1 N = 0.1(100) = 10$ e $5 < 10$.*

Exemplo 3. Ao chegarem a um cruzamento os condutores de viaturas decidem, de forma independente, virar à esquerda ou à direita, sendo a prob. de virar à esquerda 0.3 para qualquer condutor.



- (a) Determine a prob. de pelo menos 10 dos próximos 15 condutores virarem à esq.
- (b) Calcule a prob. de chegar no total mais de 3 viaturas ao entroncamento até se que se observe a primeira viragem à esquerda.

Solução:

Processo de Poisson

A distribuição de Poisson pode ser vista como um limite “especial” da distribuição binomial ou então como o número de ocorrências aleatórias de um acontecimento que se repete no tempo ou no espaço (por exemplo, o n° de clientes que chegam a um banco ou o n° de defeitos numa peça de tecido,...).

Definição: Considere-se a contagem do n° de ocorrências aleatórias de um acontecimento durante um intervalo de tempo (comprimento, área, etc). Se esse intervalo puder ser dividido em sub-intervalos de comprimento suficientemente pequeno de modo a que se verifique que:

1. A probabilidade de ocorrer mais do que um acontecimento num sub-intervalo é zero.
2. A probabilidade de uma ocorrência num sub-intervalo é constante e proporcional ao comprimento desse sub-intervalo.
3. O n° de ocorrências desse acontecimento registadas nos diversos sub-intervalos são independentes entre si.

Então esta experiência aleatória chama-se **Processo de Poisson**.

3.8 Distribuição de Poisson

Definição: Seja X uma v.a. que indica o n^o de ocorrências de um acontecimento por unidade de tempo ou de espaço (comprimento, área, etc). Diz-se que X tem **distribuição de Poisson** de parâmetro $\lambda > 0$, $X \sim \text{Poisson}(\lambda)$ se a sua função de probabilidade é dada por:

$$P(X = x) = \begin{cases} \frac{e^{-\lambda} \lambda^x}{x!}, & x = 0, 1, 2, \dots \\ 0, & \text{c.c.} \end{cases}$$

Valor esperado e variância:

$$E(X) = V(X) = \lambda$$

Nota - Verificar que a soma das probabilidades é 1:

$$\sum_{x=0}^{+\infty} P(X = x) = e^{-\lambda} \sum_{x=0}^{+\infty} \frac{\lambda^x}{x!} = e^{-\lambda} e^{\lambda} = 1$$

3.8 Distribuição de Poisson

Demonstração para o valor esperado:

$$\begin{aligned} E(X) &= \sum_{x=0}^{+\infty} x e^{-\lambda} \frac{\lambda^x}{x!} = e^{-\lambda} \sum_{x=1}^{+\infty} x \frac{\lambda^x}{x!} = e^{-\lambda} \sum_{x=1}^{+\infty} x \frac{\lambda \lambda^{x-1}}{x(x-1)!} = \\ &= e^{-\lambda} \lambda \sum_{x-1=0}^{+\infty} \frac{\lambda^{x-1}}{(x-1)!} = e^{-\lambda} \lambda e^{\lambda} = \lambda \end{aligned}$$

Distribuição de Poisson

Cálculo de probabilidades:


- ▶ Fórmula
- ▶ Programas
- ▶ Tabelas (Função de distribuição para alguns valores de $\lambda \leq 40$)

Nota:

Podemos também usar a distribuição de Poisson para calcular probabilidades aproximadas da distribuição binomial quando n grande e p pequeno (regra prática: $n > 20$ e $p < 0.1$).

Processo de Poisson:

Suponha que se registam os instantes em que ocorre certos fenômenos ao longo do tempo t unidades de tempo



Este denomina-se um processo estocástico.

Considere-se um intervalo de tempo t , que se pode dividir em subintervalos tão pequenos qto se queira. Seja

$N(t)$ = n.º ocorrências em $[0, t]$

$N(t)$ diz-se um Processo de Poisson de taxa λ , $PP(\lambda)$, $\lambda > 0$ se:

1. $N(0) = 0$
2. N = acontecimentos que ocorrem em intervalos disjuntos são independentes (incrementos independentes)
3. A dist. do n.º de ocorrências num intervalo só depende da amplitude do intervalo e não da sua localização (incrementos estacionários)
4. $\lim_{h \rightarrow 0} \frac{P(N(h)=1)}{h} = \lambda$
5. $\lim_{h \rightarrow 0} \frac{P(N(h) \geq 2)}{h} = 0$

Então $N(t) \sim Po(\lambda t)$

3.8 Distribuição de Poisson

Exemplos de situações em que pode ser aplicada(o) a(o) distribuição (processo) de Poisson:

- ▶ número de acidentes por semana num determinado cruzamento ou secção de estrada (não tendo em conta os acidentes em cadeia...)
- ▶ número de clientes que chegam a uma loja ou serviço num determinado intervalo de tempo (não tendo em conta as chegadas em grupo...)
- ▶ número de defeitos em peças ou materiais produzidos continuamente (tecidos, fios, etc.)

3.8 Distribuição de Poisson: Exemplo

Exemplo: sabemos (por observação anterior) que o número médio de defeitos por m^2 de um certo tipo de tecido é 2. Se admitirmos que estamos nas condições do Processo de Poisson, então:

- ▶ n.º de defeitos em 10 m^2 : $X_{10} \sim \text{Poisson}(20)$
- ▶ n.º de defeitos em 100 m^2 : $X_{100} \sim \text{Poisson}(200)$
- ▶ \vdots
- ▶ n.º de defeitos em $t \text{ m}^2$: $X_t \sim \text{Poisson}(2t)$

Qual é a probabilidade de não haver defeitos numa peça com 5 m^2 ? E de haver pelo menos 10 defeitos?

$$X_5 \sim \text{Poisson}(10)$$

$$P(X_5 = 0) = e^{-10} \simeq 0$$

$$P(X_5 \geq 10) = 1 - P(X_5 < 10) = 1 - P(X_5 \leq 9) = 1 - F_{X_5}(9) = 1 - 0.4579 = 0.5421 \text{ (tabela)}$$

TPC:

Exercício: Um canal de comunicação digital tem uma taxa de erro de 10^{-7} , o que significa que a probabilidade de um bit (zero ou um) chegar trocado ao destino é 10^{-7} . Em relação a uma transmissão de 10 milhões de bits (1.25 MB) calcular:

- a) a probabilidade de a transmissão ser efectuada sem erros.
- b) a probabilidade de no máximo ocorrerem 4 erros na transmissão.
- c) o valor esperado, o valor mais provável, e a mediana do número de erros que ocorrem nessa transmissão.

Soluções: a) 0.3679 b) 0.9963 c) 1; 0 e 1; 1